



中央财经大学

Central University of Finance and Economics

机器学习与美元指数收益率预测

——多期限下的可预测性与经济检验

学年学期: 2025 年秋季学期

课程名称: 高级大数据金融

课程代码:

任课教师: 张欣然

小 组: 第十二小组

总 分:

评 分 人:

小组成员名单

姓名	学号	班级
王博	2025210268	
张静怡	2025210514	
胡静文	2025210544	
陈赣维	2025210470	产教融合 4 班
汤成旭	2025210264	
谭菁	2025210556	产教融合 4 班
商芷笛	2025210577	产教融合 4 班
聂欣冉	2025210542	
蒋蕊	2025210548	
解影	2025210554	
李子平	2025210475	产教融合 4 班
赵佳	2025210558	
王梓尧	2025210476	产教融合 4 班
许士俊	2025210460	产教融合 4 班
赵攀逸	2025210464	产教融合 4 班
陈羲		

目录

一、 引言.....	4
二、 文献综述.....	4
三、 数据与变量构造.....	5
(一) 数据来源与变量构建.....	5
(二) 期限收益率.....	8
(三) 描述性统计.....	8
四、 方法与训练.....	9
(一) 预测任务与预测模型.....	9
(二) 模型选择与模型训练.....	10
五、 基本结果.....	11
(一) 评价指标与模型表现.....	11
(二) 特征重要性分析.....	13
六、 拓展分析.....	15
(一) 动态特征重要性分析.....	15
(二) 经济检验分析.....	17
七、 总结.....	21

一、引言

浮动汇率制度下，名义汇率短期波动往往接近随机游走，传统基于宏观基本面的结构模型在样本外预测中难以稳定战胜基准（“Meese–Rogoff puzzle”）。随着高频金融数据与计算能力提升，机器学习为刻画汇率决定因素的非线性、交互与状态依赖提供了新路径。本文以美元指数为研究对象，构建涵盖宏观基本面（利率、通胀、产出缺口等）、大宗商品与全球市场指数、情绪与政策不确定性，以及美元指数技术指标的多维特征体系，形成 2006 年 3 月 29 日至 2025 年 10 月 31 日的日度样本。在时间序列样本外框架下，我们以无漂移随机游走为基准，分别在 $H=1、5、10、20$ 个交易日持有期上比较正则化线性模型与非线性模型的预测表现，并采用拓展窗口交叉验证与滚动再训练以控制前视偏差与过拟合。除统计指标外，本文进一步展开滚动特征重要性分析以增强可解释性，并在考虑交易成本的经济检验下评估预测模型的经济价值。

二、文献综述

浮动汇率制度确立后，大量研究尝试解释与预测名义汇率变动，但在样本外预测中普遍难以击败随机游基准。Mees and Rogoff（1983）系统比较了货币模型和时间序列计量模型的样本外预测表现，结论是：即便使用当期或滞后基本面变量，结构模型在 1–12 个月的预测期内通常无法显著优于随机游走，形成所谓 Meese–Rogoff puzzle。

针对这一难题，后续文献选择进一步检验研究汇率的可预测性。Mark（1995）提出，在更长预测期上，货币供给与产出可能对汇率具有预测力。Cheung et al.（2005）重新评估了 1990 年代以来的预测模型，整体结论依然谨慎：在不同货币对、不同预测期与不同估计方式下，结构模型相对随机游走的优势并不稳定。Molodtsova and Papell（2012）考察了泰勒规则及其变体模型对汇率的样本外预测能力，指出所有泰勒规则模型在危机时期的预测表现都优于随机游走基准，包含了估计系数（estimated coefficients）和失业缺口（unemployment gap）的泰勒规则模型在危机后也具备超过基准的预测能力。Evans and Lyons（1999）的研究显示，在日度频率层面，利用订单流量可以显著提高对汇率变动的解释度，并获得

优于随机游走的短期样本外预测表现。

在综述层面，Rossi（2013）对汇率是否可预测、何时可预测、哪些变量可预测进行了系统梳理，强调汇率可预测性高度依赖于样本期、预测期、模型设定、数据频率以及评价统计量的选择；很多显著的预测结果在不同样本外窗口或不同损失函数下并不稳健。

随着数据可得性提升与计算能力增强，机器学习方法也被用于刻画汇率决定因素的非线性关系。Pompeu and Rossi（2022）利用 SVM 和随机森林等机器学习预测汇率，得到了优于随机游走模型的结果。Pfahler（2022）利用 XGBoost 和深度学习网络进行研究，发现模型在预测汇率变动的方向上表现出色。

需要指出的是，应用机器学习进行资产价格预测时，预测模型的性能不仅取决于算法复杂度，更取决于时间序列数据的训练、验证、测试的切分、超参数选择与过拟合控制。Gu（2020）在资产定价视角下系统比较多类机器学习方法，指出树模型与神经网络在允许非线性交互方面往往带来经济增益，同时样本外检验与可解释性分析对于可信结论也至关重要；Nagel（2021）也强调将经济学约束与经济含义纳入机器学习设计与解释框架。

综上，既有研究表明：汇率短期变动在统计上接近随机游走，传统的货币模型和时序计量模型不能很好地捕捉到影响汇率的因素。但在特定预测期、特定频率与更复杂的模型上，仍然可以有效预测汇率的变化。本文在样本外预测框架下，构建了以汇率收益率为预测对象的机器学习预测体系，对比随机游走基准模型，并进一步从经济意义与可解释性的角度检验预测结果的稳健性与金融合理性。

三、数据与变量构造

（一）数据来源与变量构建

本文综合多篇汇率预测文献进行变量选择，最终将本文所研究解释变量划分为四类：宏观基本指标、国际大宗商品价格与市场指数、市场情绪与政策不确定性、以及基于美元指数构造的技术指标。相关的数据来源、频率报告在表 1 中。

表 1 研究变量来源频率与观测值

类型	变量名	来源	频率
宏观基本指标	美元指数 USD	Investing Finance	日度
	美元兑货币汇率 USD_{GBP, EUR, JPY, CNY}		
	三个月国债利率 {USD, UK, GER}_3M		
	十年期国债利率 {USD, UK, GER, JP, CN}_10Y		
	期限利差 {US, UK, GER}_TermSpread		
	国内产出同比增长率 GDP	FRED	季度
	国内物价同比增长率 {US, Euro, JP, CN}_CPI	IMF-IFS Database	月度
	国内产出缺口 Output Gap	FRED	季度
	美元指数期货 USD_Futures	Investing Finance	日度
	黄金期货价格 GOLD		
国际大宗商品价格与 市场指数	原油期货价格 WTI		
	市场指数 {US, UK, GER, JP, CN, HK}_Mkt_Index		
	政策不确定性指数 EPU	Baker et al. (2016)	日度
市场情绪与政策不确定性	期权隐含波动率 VIX	Investing Finance	
	移动平均偏离度 MA_Gap	计算合成	日度
美元指数技术指标	布林带宽度 BBW		
	收益率滞后项 ret_lag		

其中宏观基本指标中，美元兑英镑、美元兑欧元采用美元标价法，美元兑日元、美元兑人民币采用日元和人民币标价法。期限利率差是各个国家内三个月期

国债利率与十年期国债利率的差值，国内产出增长率、物价指数增长率、产出缺口均是季度同比增长率，其中国内产出增长率和产出缺口只选择了美国的数据。美元指数期货采用 DXZ5 合约的价格进行研究；大宗商品价格和市场指数中，黄金价格采用黄金期货（GCc1）合约价格，原油采用 WTI 期货（CL）合约价格。美国市场指数选取为标准普尔 500 指数、英国为富时 100 指数、德国为 DAX30 指数、日本为日经 225 指数、中国为沪深 300 指数、香港为恒生指数；政策不确定性指数是根据 Baker et al.（2016）提出并持续发布的美国日度政策不确定性指数。¹技术指标中，移动平均偏离度和布林带宽度计算是基于美元指数。

在数据期的选择上，本文以美元指数（USD）的可得交易日为主时间轴，所有其他变量均对齐到该时间轴。同时为避免引入非交易日噪声，默认剔除周末日期。因为交易日不同产生的数据缺失通过向前填充（carry forward）处理。

在变量处理上，我们总共进行了对数差分、序列做差、不处理、计算合成四种处理方法。具体结果汇报在表 2 中。其中对数差分是指对序列先进行对数化处理，随后再进行差分计算：

$$\text{logdiff}(S_t) := \ln(S_t) - \ln(S_{t-1}) \tag{1}$$

表 2 数据处理方法

类型	变量名	处理方法
宏观基本指标	USD	对数差分
	USD_{GBP, EUR, JPY, CNY}	对数差分
	{USD, UK, GER}_3M	不处理
	{USD, UK, GER, JP, CN}_10Y	不处理
	{US, UK, GER}_TermSpread	序列做差
	GDP	不处理
	{US, Euro, JP, CN}_CPI	不处理
	Output Gap	不处理
国际大宗商品价格	USD_Futures	对数差分

¹ <https://www.policyuncertainty.com/index.html>

与市场指数	GOLD	对数差分
	WTI	对数差分
	{US, UK, GER, JP, CN, HK}_Mkt_Index	对数差分
市场情绪与政策不确定性	EPU	对数差分
	VIX	不处理
美元指数技术指标	MA_gap	计算合成
	BBW	计算合成
	Ret_Lag	计算合成

(二) 期限收益率

本文的预测对象为美元指数在未来一定窗口内的对数收益率。设 S_t 为第 t 日的美元指数收盘价，预测窗口为 H （以交易日步长计），则定义未来 H 日内的美元指数收益率为公式 2 中的形式，该定义表示一段时间内的累计收益。

$$y_t^{(h)} := \ln(S_{t+H}) - \ln(S_t) \tag{2}$$

(三) 描述性统计

根据前述定义的处理方法，以 1 日的期限收益率预测为例，我们将原始数据处理之后的描述性统计汇报在表 3 中。最终合并数据后，我们得到 2006 年 3 月 29 日至 2025 年 10 月 31 日的共计 5088 条数据记录。

表 3 变量描述性统计（H=1）

变量名	Count	Mean	SD	Min.	Max.
USD	5176	1.76	0.00470	-0.031	0.0252
USD_GBP	5176	1.74	0.00477	-0.0274	0.0236
USD_EUR	5176	5.14	0.00588	-0.0308	0.0840
USD_JPY	5176	0.44	0.00558	-0.0368	0.0292
USD_CNY	5176	5.67	0.00625	-0.0386	0.0622
GDP	5177	2.05	2.25	-7.40	12.4
US_CPI	5147	2.55	1.94	-2.10	9.06
Euro_CPI	5177	2.13	2.03	-0.642	10.6
JP_CPI	5177	0.81	1.45	-2.52	4.39

CN_CPI	5177	2.18	1.96	-1.79	8.805
Output Gap	5177	-0.88	2.17	-9.024	2.164
USD_Futures	5176	1.74	0.00477	-0.0274	0.0236
GOLD	5176	4.04	0.0112	-0.0982	0.086
WTI	5176	-1.83	0.0271	-0.569	0.581
US_Mkt_Index	5176	3.25	0.0121	-0.128	0.110
UK_Mkt_Index	5176	1.02	0.0110	-0.115	0.0938
GER_Mkt_Index	5176	2.88	0.0130	-0.121	0.108
JP_Mkt_Index	5175	2.19	0.0143	-0.132	0.132
CN_Mkt_Index	5175	3.06	0.0156	-0.0970	0.0893
HK_Mkt_Index	5176	1.07	0.0148	-0.142	0.134
EPU	5176	2.88	0.540	-4.402	3.970
VIX	5177	19.5	8.72	9.14	82.7

注：USD、USD_{GBP, EUR, JPY, CNY}、USD_Futures、WTI、汇报的平均值均放大为原来的 10^5 倍，GOLD、{US, UK, GER, JP, CN, HK}、EPU 汇报的平均值放大为原来的 10^4 倍。对于后续的分析，我们仍然采用原始未放大的数据。

四、方法与训练

(一) 预测任务与预测模型

本部分介绍预测的任务和预测所用的模型。本文研究的预测任务为公式(2)所定义的美元指数未来 H 个交易日的累计对数收益率。在每个交易日 t ，仅使用截至 t 日可得的信息集生成对 $y_t^{(H)}$ 的点预测。本文分别在 $H=1,5,10,20$ 的预测期限上，基于上文的数据处理方法构建数据集，并在同一套样本外评估框架下比较不同方法的预测性能和经济含义。

在模型选择上，本文的基准模型采用无漂移随机游走（random walk without drift），该基准在汇率预测文献中被广泛采用，可用于衡量任何比较模型的增益。在该模型中，未来收益率的最优预测为当前收益率，因此对数收益的基准预测为零。在比较模型中，采用线性模型和树模型，线性模型提供清晰的可解释结构，并通过正则化缓解高维特征下的多重共线性与过拟合风险，包括 LASSO、Ridge 和 ElasticNet。树模型能够捕捉非线性、阈值效应以及变量交互项，对潜在结构变化更具稳健性，包括 RandomForest、XGBoost 和 LightGBM。

(二) 模型选择与模型训练

本部分将介绍模型超参数的选择方法以及模型的训练方法。首先，为了避免前视偏差（look-ahead bias），样本按时间顺序划分为训练验证集（80%）与测试集（20%）。模型的超参数选择仅在测试验证集内完成，测试集仅用于最终样本外评估。其次，在超参数选择阶段，本研究采用基于时间顺序而非随机打乱式的方式进行交叉验证，本文采用拓展窗口（Expanding Window）的方式对模型进行超参数的选择：训练窗口随时间扩展，验证窗口在时间轴上向前滚动。每类模型在给定超参数集合中，在训练验证集中逐一训练并计算验证损失，以验证损失的时间序列 RMSE 平均值作为选择准则，选取最优超参数组合。最后，在训练过程中，对还额外对线性模型进行了特征标准化的处理。

表 4 模型的超参数范围和最优参数（H=1）

模型名称	参数名称	最优参数
LASSO	alpha	0.0001
Ridge	alpha	100
Elastic Net	alpha	0.0001
	l1_ratio	0.6
Random Forest	n_estimators	1000
	max_depth	5
	min_samples_leaf	1
	max_features	0.5
XGBoost	n_estimators	500
	max_depth	2
	learning_rate	0.01
	subsample	0.8
	colsample_bytree	0.8
	reg_lambda	5.0
LightGBM	n_estimators	800
	num_leaves	31
	learning_rate	0.008
	subsample	0.8
	colsample_bytree	0.8
	reg_lambda	5.0
	max_depth	3
	Force_col_wise	true

在模型训练好超参数之后，模型将在测试集中评估样本外表现。对于每一个测试样本，我们采用拓展窗口的方法进行训练和预测，对于每一个预测点都利用该时点之前的历史数据重新训练模型的参数，随后对测试点生成预测。我们将每个模型以及其最优参数汇报到表 4 中

五、基本结果

(一) 评价指标与模型表现

本节基于测试集进行样本外预测评估。测试集中可用于评价的观测点数为 1018。预测期设置为 $H \in \{1, 5, 10, 20\}$ ，分别对应预测未来 1/5/10/20 个交易日持有期收益率预测，并通过样本外 R^2 (OOS R^2) 衡量模型相对于随机游走基准模型的改进程度，如果样本外 $R^2 > 0$ 则表示模型在测试集上优于基准；通过均方误差 (MSE)、均方根误差 (RMSE) 与平均绝对误差 (MAE)，用于衡量点预测误差大小；通过方向准确率 (Sign Accuracy) 比较预测收益率的正负与实际观测值是否一致，评价模型刻画方向预测的能力。表 5 汇总了不同预测期下各模型相对基准的最优模型表现。结果显示，短期 ($H=1$) 整体改进幅度有限，正则化线性模型可取得稳定的小幅优势；随着预测期拉长 ($H=5/10/20$)，基于树的模型（尤其是 LightGBM）表现显著提升，样本外 R^2 与方向准确率均取得明显上升，最大分别达到了 71.2% 和 85.9% ($H=20$)，显示出树模型在中短期趋势预测上的预测能力。

表 5 不同预测期下的模型表现

模型	RMSE	MAE	OOS R^2 (%)	Sign Accuracy (%)
H=1				
Random Walk	0.00465	0.00348	0.00	-
LASSO	0.00462	0.00346	1.63	52.8
Ridge	0.00461	0.00346	1.72	54.0
Elastic Net	0.00460	0.00345	2.21	52.0
Random Forest	0.00463	0.00348	1.08	48.6
XGBoost	0.00463	0.00347	1.02	49.4
LightGBM	0.00467	0.00350	-0.53	47.7
H=5				
Random Walk	0.0100	0.00753	0.00	-

LASSO	0.0100	0.00752	0.00	51.6
Ridge	0.0102	0.00770	-3.10	52.2
Elastic Net	0.0100	0.00752	0.00	51.6
Random Forest	0.00976	0.00735	4.82	56.8
XGBoost	0.00985	0.00742	3.00	56.0
LightGBM	0.00971	0.00730	5.68	58.0
H=10				
Random Walk	0.0140	0.0110	0.00	-
LASSO	0.0140	0.0110	0.03	51.1
Ridge	0.0142	0.0112	-2.67	53.0
Elastic Net	0.0140	0.0110	0.03	51.1
Random Forest	0.0127	0.0100	17.4	64.0
XGBoost	0.0133	0.0104	10.4	58.9
LightGBM	0.0125	0.0097	20.2	64.4
H=20				
Random Walk	0.0202	0.0165	0.00	-
LASSO	0.0202	0.0165	0.08	50.7
Ridge	0.0204	0.0164	-2.62	54.1
Elastic Net	0.0202	0.0165	0.08	50.7
Random Forest	0.0156	0.0126	40.5	73.6
XGBoost	0.0181	0.0147	19.7	64.4
LightGBM	0.0108	0.0084	71.2	85.9

在 $H=1$ 的短期预测中，除了 LightGBM 外所有预测模型均取得正的样本外 OOS R^2 和轻微的预测误差大小与方向的改进，其中 ElasticNet 最优（OOS $R^2=0.0221$, $MSE=0.00460$, $MAE=0.00345$, Sign Accuracy=52.0%）。该结果表明短期内，收益率更接近高频扰动与微观噪声的叠加，真实可预测成分通常较弱，此时模型需要稳定地从弱信号中提取可泛化的预测成分这个时候线性模型通过正则化方法抑制样本内过拟合，能够在样本外框架下取得小幅的预测改进。而随 H 变大时，数据的信噪比提高，驱动汇率的因素往往从短期噪声转向更有规律的风险溢价机制。而当存在足够结构性信号时，树模型可以通过分裂与集成捕捉更复杂的非线性结构，从而在更长预测期下显著改善模型的预测表现。图 1 通过可视化的方式汇报了 Ridge 模型与 LightGBM 在不同预测期限下的预测效果。




图 1 Ridge 与 LightGBM 在不同预测期限下的预测效果

(二) 特征重要性分析

针对特征重要性分析上，本文采用置换重要性（Permutation Importance）刻画变量对模型预测误差的边际贡献。具体做法为：在保持测试集其它变量不变的前提下，对单一特征列进行观测值随机置换，破坏其与目标变量的对应关系，并计算模型预测损失（本文以 MSE 为基准）的增量。置换后损失上升越多，说明该特征对模型预测越关键。特征重要性的相关结果汇报在表 6 中。

从各个模型的特征重要性评估看，短期（ $H=1$ ）预测中资产价格的信号更重要。以 Ridge 模型为例， $H=1$ 时重要性主要集中在美元指数相关外汇与美元指数变动上，其中相关汇率变动（如 USD_EUR、USD_JPY、USD_GBP、USD_CNY）的特征重要性占总和的约 37.2%，美元指数期货约占 23.0%。此外滞后收益与美国股市收益也进入前列，反映短期汇率收益更受美元汇率与资产价格的冲击驱动，而宏观基本面，比如通胀、利率对于 1 日对收益波动的解释力相对有限。

随着预测期限逐渐变长，宏观通胀与利率期限结构的重要性显著上升，树模型对非线性与交互的刻画优势更突出。以表现最优 LightGBM 为例， $H=5$ 时美国、日本和欧盟的通胀重要性占特征重要性总和的 46.5%，其次是均线偏离、波动带宽等技术指标； $H=10$ 时通胀占比进一步提高至 55.4%，同时利率期限结构

与产出缺口的权重提升，说明在更长持有期下，通胀差异、利率预期、以及增长前景更可能通过货币政策路径与风险溢价渠道逐步反应到汇率走势上。

长期 ($H=20$) 预测中，汇率预测受到宏观基本面与技术指标共同主导。以 LightGBM 为例，利率指标 US_10Y 占到特征重要性总和的 14.2%，同时也是模型认为最重要的预测特征。同时 Euro_CPI、US_CPI（共计占 18.6%）等通胀变量也具有显著贡献。从类别占比看， $H=20$ 时 LightGBM 模型中利率类变量（三个月和十年期利率、以及对应的期限结构差）占到了总体特征重要性的 33.2%，通胀类变量占据了总和的 29.8%，两类指标合计占比超过六成；与此同时，技术类变量（BBW_5、BBW_20、BBW_60、MA_gap_5、MA_gap_20、MA_gap_60）合计约占总和的 23.6%，反映多周尺度的汇率收益率受到宏观变量与技术变量的综合影响。

同时应当注意的是，线性模型在 H 增大后的预测效果相对变差而树模型相对变好。尤其是 Lasso 与 ElasticNet 模型在 $H \geq 5$ 时倾向于将多数系数收缩为 0 并输出近似常数的预测，以至于在中长期预测中未能取得相对随机游走更优的结果，提示中长期的可预测信号更可能表现为非线性或强交互结构，而非简单的线性关系。综上我们推测，一方面， H 增大时，收益中高频噪声被一定程度平滑，宏观与风险溢价等低频因素的信噪比提高，使得预测结构更容易被模型捕捉到；另一方面，产出、通胀、利率对汇率的影响往往随着时间发生变化，而线性模型以固定系数刻画平均效应，难以同时适配不同状态，从而样本外表现下降。相比之下，树类模型通过分裂与集成能够自然表达非线性交互与异质性，因此在更长期限下获得更稳定的误差改进。

表 6 模型特征重要性

模型	1 st	2 nd	3 rd	4 th	5 th
H=1					
LASSO	US_Mkt_Index	USD_Futures	USD_EUR	US_CPI	MA_gap_5
Ridge	USD_EUR	USD_Futures	ret_lag_1	US_Mkt_Index	US_CPI
ElasticNet	USD_Futures	USD_EUR	US_Mkt_Index	MA_gap_5	USD_GBP
RandomForest	US_Mkt_Index	USD_GBP	Euro_CPI	USD_EUR	ret_lag_5
XGBoost	US_Mkt_Index	USD_EUR	Euro_CPI	US_CPI	USD_GBP
LightGBM	US_Mkt_Index	USD_EUR	JP_CPI	BBW5	USD_Futures

H=5					
LASSO	-	-	-	-	-
Ridge	US_CPI	Euro_CPI	ret_lag_1	USD_EUR	USD_Futures
ElasticNet	-	-	-	-	-
RandomForest	US_CPI	Euro_CPI	US_10Y	JP_CPI	US_3M
XGBoost	Euro_CPI	US_CPI	JP_CPI	BBW_20	MA_gap_20
LightGBM	US_CPI	JP_CPI	MA_gap_20	Euro_CPI	BBW_20
H=10					
LASSO	-	-	-	-	-
Ridge	Euro_CPI	US_CPI	JP_10Y	US_3M	US_10Y
Elastic Net	-	-	-	-	-
Random Forest	US_CPI	Euro_CPI	US_10Y	JP_CPI	US_3M
XGBoost	Euro_CPI	US_CPI	JP_CPI	UK_TermSpread	Output_Gap
LightGBM	US_CPI	Euro_CPI	JP_CPI	Output_Gap	UK_TermSpread
H=20					
LASSO	-	-	-	-	-
Ridge	Euro_CPI	US_CPI	US_10Y	JP_10Y	US_3M
Elastic Net	-	-	-	-	-
Random Forest	Euro_CPI	US_10Y	US_CPI	US_3M	CN_CPI
XGBoost	Euro_CPI	US_10Y	JP_CPI	US_CPI	CN_CPI
LightGBM	US_10Y	Euro_CPI	BBW_60	US_CPI	MA_gap_60

注：从左到右（1st至 5th分别表示模型认为前五重要的特征），受限于篇幅，这里只展示前五重要特征并且不展示重要性数值。

六、拓展分析

(一) 动态特征重要性分析

表 6 中的在特征重要性基于全测试集上给出了各模型在不同预测期限下的关键预测因素。然而，汇率决定机制可能随宏观环境与风险偏好变化而发生结构性漂移，基于全样本评估的特征重要性难以反映这种时变性。因此，本节进一步检验特征重要性在测试期内的重要性变化以增强对模型预测的可解释性。

具体来说，我们在测试集上进行滚动窗口的动态评估：对每个模型与每个预

测期，以窗口长度 252 个交易日为单位从测试集上选取测试区间，按照窗口步长 21 个交易日向前滚动，逐渐覆盖整个测试集。在每一个窗口中，模型仅使用窗口起点之前当时可得的历史样本进行训练，然后在测试窗口中计算特征重要性。针对线性模型，采用置换重要性进行计算，每个测试窗口内重复置换 3 次并取平均值作为特征重要性，最终得到随时间变化的特征重要性序列。根据此序列，我们通过可视化的方法计算了各个模型特征重要性的时间序列图，并将部分 $H=1$ 与 $H=20$ 的结果汇报在图 2 与图 3 中。




图 2 Ridge 模型的滚动特征重要性 ($H=1$)




图 3 RF 模型的滚动重要性特征 ($H=20$)

基于分析可以发现，短期 ($H=1$) 来看以汇率收益率与与美元指数期货、美元与其他币种的汇率因素相关。以 Ridge 为例，模型中对预比较重要的特征为 USD_EUR 和 USD_Futures；中长期 ($H=5,10,20$) 来看持续重要的特征逐步过渡

到利率变量、通胀变量与技术指标变量。以 Random Forest 为例，对模型预测具有稳定重要性的变量有 US_10Y、US_TermSpread、BBW_60、US_CPI 等变量。

(二) 经济检验分析

数值意义上的预测改进并不必然转化为可交易的经济收益。在这一部分我们尝试在经济层面构建基于预测信号的简单交易策略，并在考虑交易成本后评估其风险调整收益，以检验模型的经济价值。

首先我们将模型的预测的收益率视为仓位调整的信号，根据公式 (3)，我首先设定一个交易阈值，作为仓位调整的激活项。当预测收益率高于这个激活项时，投资仓位就增加一个单位，当预测收益率低于这个激活项的负值时，就减少一个单位的仓位，否则就保持原来的仓位。同时我们按照公式 (4) 为每次交易仓位的调整设置了一个固定费率作为换仓的成本。

$$\text{pos}_t = \begin{cases} +1 & \hat{y}_t > \tau \\ 0 & |\hat{y}_t| \leq \tau \\ -1 & \hat{y}_t < -\tau \end{cases} \quad (3)$$

$$\text{cost}_t := t_c |\text{pos}_t - \text{pos}_{t-1}| \quad (4)$$

其中 τ 代表仓阈值， t_c 代表调整仓位的费用。最后通过计算仓位对应的投资收益率，减去仓位调整成本，就能得到投资净收益率。

其次，为了对应不同的预测期 H 的投资决策，我们把测试集的交易日分成 $0, 1, \dots, H-1$ 共计 H 组，每个组称为一个阶段 (phase)。这样每一组里的交易日就自然相隔 H 天。然后我们按照公式 (5) 计算了每个阶段中，每个交易日的收益率序列，并依据这些序列计算了阶段内的收益率、波动率和年化夏普比率，以及换手率、命中率与最大回撤等指标，作为单个模型在每个阶段里的表现。最后取单个模型在 H 个阶段的指标结果的平均值，作为模型的整体投资表现，相关的经济检验结果汇总在表 7 中。根据 Sharpe 比率，不同预测期下的最佳模型是 Ridge 模型（预测期限 $H=1$ ，调仓成本 1%，夏普比率 1.66）、Random Forest（预测期限

H=5, 调仓成本 5‰, 夏普比率 1.42)、LightGBM (预测期限 H=10, 调仓成本 1‰, 夏普比率 2.10)、LightGBM (预测期限 H=20, 调仓成本 1‰, 夏普比率 3.75)。

$$r_{net,t} := pos_t \times y_{true,t} - cost_t \tag{5}$$

表 7 模型经济检验表现						
模型	换仓成本	对数收益率	年化夏普比率	命中率	换手率	最大回撤
H=1						
Always Long	0	0.09	0.13	0.51	0	-0.15
Elastic Net	0	0.21	0.72	0.51	0.89	-0.15
	5‰	0.28	1.48	0.18	0.43	-0.09
	1‰	0.12	0.98	0.06	0.14	-0.03
Lasso	0	0.27	0.92	0.52	0.93	-0.14
	5‰	0.18	1.06	0.13	0.31	-0.09
	1‰	0.09	0.89	0.03	0.06	-0.02
Ridge	0	0.36	1.22	0.53	0.74	-0.07
	5‰	0.28	1.21	0.29	0.59	-0.10
	1‰	0.29	1.66	0.16	0.34	-0.04
Random Forest	0	-0.02	-0.06	0.48	0.37	-0.18
	5‰	0.05	0.50	0.02	0.07	-0.03
	1‰	0.03	0.50	0.00	0.02	-0.02
XGBoost	0	0.00	0.01	0.49	0.56	-0.23
	5‰	0.09	0.55	0.09	0.16	-0.05
	1‰	0.09	0.78	0.03	0.08	-0.04
LightGBM	0	-0.14	-0.48	0.47	0.72	-0.32
	5‰	0.09	0.49	0.14	0.29	-0.15
	1‰	0.01	0.11	0.06	0.16	-0.10
H=5						
模型	换仓成本	对数收益率	年化夏普比率	命中率	换手率	最大回撤
Always Long	0	0.19	0.14	0.52	0	-0.15
ElasticNet	0	0.19	0.14	0.52	0	-0.15
	5‰	0	-	0	0	0
	1‰	0	-	0	0	0
Lasso	0	0.19	0.14	0.52	0	-0.15
	5‰	0	-	0	0	0
	1‰	0	-	0	0	0
Ridge	0	0.66	0.47	0.52	0.28	-0.12
	5‰	0.74	0.55	0.47	0.29	-0.11

	1‰	0.52	0.43	0.39	0.27	-0.11
RandomForest	0	1.58	1.14	0.57	0.28	-0.05
	5‰	1.65	1.42	0.37	0.25	-0.03
	1‰	1.12	1.15	0.22	0.19	-0.04
XGBoost	0	1.26	0.90	0.56	0.41	-0.07
	5‰	1.22	1.10	0.31	0.28	-0.05
	1‰	0.95	0.95	0.22	0.19	-0.05
LightGBM	0	1.59	1.15	0.58	0.49	-0.06
	5‰	1.69	1.35	0.45	0.43	-0.05
	1‰	1.40	1.24	0.34	0.39	-0.05

H=10

模型	换仓成本	对数收益率	年化夏普比率	命中率	换手率	最大回撤
Always Long	0	0.35	0.13	0.51	0	-0.14
ElasticNet	0	0.35	0.13	0.51	0	-0.14
	5‰	-0.02	-0.02	0.01	0.02	-0.02
	1‰	0	-	0	0	0
Lasso	0	0.35	0.13	0.51	0	-0.14
	5‰	-0.02	-0.02	0.01	0.02	-0.02
	1‰	0	-	0	0	0
Ridge	0	0.96	0.34	0.53	0.20	-0.12
	5‰	1.02	0.37	0.50	0.20	-0.12
	1‰	1.02	0.39	0.46	0.23	-0.11
RandomForest	0	4.86	1.87	0.64	0.40	-0.04
	5‰	4.62	1.87	0.55	0.40	-0.04
	1‰	4.24	1.81	0.46	0.36	-0.04
XGBoost	0	3.34	1.24	0.59	0.36	-0.05
	5‰	3.26	1.33	0.47	0.39	-0.04
	1‰	3.06	1.40	0.39	0.37	-0.04
LightGBM	0	4.81	1.85	0.64	0.59	-0.05
	5‰	4.95	1.99	0.59	0.57	-0.04
	1‰	4.99	2.10	0.55	0.56	-0.03

H=20

模型	换仓成本	对数收益率	年化夏普比率	命中率	换手率	最大回撤
Always Long	0	0.70	0.12	0.51	0	-0.14
ElasticNet	0	0.70	0.12	0.51	0	-0.14
	5‰	0.36	0.07	0.40	0.04	-0.11
	1‰	-0.01	0.07	0.02	0.04	-0.02
Lasso	0	0.70	0.12	0.51	0	-0.14
	5‰	0.36	0.07	0.40	0.04	-0.11
	1‰	-0.01	0.07	0.02	0.04	-0.02
Ridge	0	2.13	0.37	0.54	0.27	-0.11

RandomForest	5‰	1.96	0.35	0.52	0.27	-0.11
	1‰	1.83	0.33	0.51	0.28	-0.11
	0	10.76	2.23	0.74	0.56	-0.03
	5‰	10.82	2.32	0.71	0.57	-0.03
	1‰	10.66	2.36	0.68	0.57	-0.03
XGBoost	0	6.89	1.29	0.64	0.66	-0.05
	5‰	6.95	1.39	0.57	0.62	-0.04
	1‰	6.85	1.45	0.51	0.57	-0.04
LightGBM	0	14.5	3.72	0.86	0.84	-0.02
	5‰	14.48	3.72	0.85	0.83	-0.02
	1‰	14.49	3.75	0.83	0.83	-0.02

注：对数收益率在 $H=1,5,10,20$ 时均展示为原始数值的 10^3 倍。命中率表示模型预测的收益率方向的准确率。

第一，通过分析我们发现，长期持有的基准策略年化夏普比率仅为 0.12–0.14、平均对数收益为 0.09-0.70，平均最大回撤约为 -13.66% 到 -15.32%。与其他机器学习模型相比，单一的买入-持有策略无法提供有吸引力的风险调整收益，而且尾部风险（回撤）较大。对比基准策略，四个预测窗口期内最优模型的 Sharpe 提升分别约为 1.53、1.29、1.98 和 3.63，同时最大回撤改善约为 10~12 个百分点。说明预测的改进不仅是数值意义的，在扣除交易成本后，仍然能转化为显著的风险调整收益与更可控的投资风险。

第二，投资表现呈现显著的期限结构趋势。随着 H 增大，最优模型的年化 Sharpe 明显提升。推测是交易期限越长，预测的模式越能够被模型识别，从而更好地管理收益与风险。

第三，调仓阈值对最优模型有一定影响。以预测期限 $H=1$ 的 Ridge 模型为例，当 $\tau=0$ 时年化 Sharpe 为 1.22、最大回撤为 -7.44%、换手率为 0.737；将阈值提高至 $\tau=1‰$ 后，Sharpe 提升至 1.66、回撤减小至 -4.16%，换手率下降至 0.345。对 $H=5$ 而言，随机森林模型在 $\tau=5‰$ 处达到最优的夏普比率（1.42），而过低或过高均导致夏普比率降低。对较长持有期 $H=10$ 或 20 而言，LightGBM 的夏普比率随 τ 增大呈单调改善或基本不变，说明短期内阈值的提高通过减少弱信号交易降低了换手率与成本，从而改善风险调整收益。中长期信号更强、弱信号过滤不会显著损失收益，反而有助于降低噪声交易。

综合而言，在扣除交易成本评估下，模型策略在各个预测期限上均显著优于

方向性基准，且优势随持有期延长而增强；其中长期来看由 LightGBM 取得最高 Sharpe 与最小回撤，表明机器学习模型预测具有明确的经济价值。

七、总结

本文以美元指数未来 $H \in \{1, 5, 10, 20\}$ 个交易日累计对数收益为预测对象，基于 2006-03-29 至 2025-10-31 日度样本建立样本外预测框架，并以无漂移随机游走为基准比较不同模型。结果显示： $H=1$ 下整体改进较小，但正则化线性模型更稳健，其中 ElasticNet 在测试集上取得 OOS $R^2=2.21\%$ 、方向准确率 52.0%；当 H 增大到 5/10/20 时，树模型优势显著扩大，LightGBM 在 $H=20$ 下 OOS R^2 与方向准确率分别达到 71.2% 与 85.9%。

解释性分析表明，关键信息来源随预测期从高频到宏观迁移： $H=1$ 更依赖汇率与美元指数期货（如 USD_EUR、USD_Futures）；而 $H \geq 5$ 时，利率、期限利差、通胀与技术指标的重要性上升（如 US_10Y、US_TermSpread、BBW_60、US_CPI）。

在经济检验中，我们将预测值映射为仓位信号并计入换仓成本，同时采用阶段分组避免持有期重叠；结果提示统计层面的预测改进在一定条件下可以转化为可交易的风险调整收益。

综上，本文认为机器学习在特定预测期上可缓解汇率预测不如随机游走的难题。同时后续可引入更贴近现实交易摩擦与风险约束、引入更加复杂的预测模型，进一步检验不同环境下的汇率可预测性与预测稳健性。

参考文献

- [1] Richard A. Meese, Kenneth Rogoff, Empirical exchange rate models of the seventies: Do they fit out of sample? , *Journal of International Economics*, Volume 14, Issues 1–2, 1983, Pages 3-24, ISSN 0022-1996, [https://doi.org/10.1016/0022-1996\(83\)90017-X](https://doi.org/10.1016/0022-1996(83)90017-X).
- [2] Mark, Nelson, (1995), Exchange Rates and Fundamentals: Evidence on Long-Horizon Predictability, *American Economic Review*, 85, issue 1, p. 201-18, <https://EconPapers.repec.org/RePEc:aea:aecrev:v:85:y:1995:i:1:p:201-18>.
- [3] Cheung Y W, Chinn M D, Pascual A G. Empirical exchange rate models of the nineties: Are any fit to survive?[J]. *Journal of international money and finance*, 2005, 24(7): 1150-1175.
- [4] Tanya Molodtsova and David Papell, "Taylor Rule Exchange Rate Forecasting During the Financial Crisis," NBER Working Paper 18330 (2012), <https://doi.org/10.3386/w18330>.
- [5] Martin D.D. Evans and Richard K. Lyons, "Order Flow and Exchange Rate Dynamics," NBER Working Paper 7317 (1999), <https://doi.org/10.3386/w7317>.
- [6] Rossi, B. (2013). Exchange Rate Predictability. *Journal of Economic Literature*, 51(4), 1063–1119. <http://www.jstor.org/stable/23644817>.
- [7] Pfahler, J.F. Exchange Rate Forecasting with Advanced Machine Learning Methods. *J. Risk Financial Manag.* **2022**, *15*, 2. <https://doi.org/10.3390/jrfm15010002>.[] Pompeu G, Rossi J L. Real/Dollar Exchange Rate Prediction Combining Machine Learning and Fundamental Models[J]. 2022.
- [8] Gu S, Kelly B, Xiu D. Empirical asset pricing via machine learning[J]. *The Review of Financial Studies*, 2020, 33(5): 2223-2273.
- [9] Nagel, Stefan. *Machine Learning in Asset Pricing*. Princeton University Press, 2021. *JSTOR*, <https://doi.org/10.2307/j.ctv19fvx8r>. Accessed 22 Dec. 2025.
- [10] Baker, S. R., N. Bloom, and S. J. Davis, 2016. "Measuring Economic Policy Uncertainty," *Quarterly Journal of Economics*, 131, no. 4 (November), 1593-1636.